## Breve introducción a la programación en paralelo

José Carlos García





## Introducción



► Supongamos que **tenemos un restaurante.** 



- Supongamos que tenemos un restaurante.
- ▶ Si tenemos una persona trabajando a una velocidad media, y nuestro restaurante hay n = 10 mesas ocupadas, ¿Qué sucede?



- Supongamos que tenemos un restaurante.
- ▶ Si tenemos una persona trabajando a una velocidad media, y nuestro restaurante hay n = 10 mesas ocupadas, ¿Qué sucede?
- Dado que tenemos una persona, y no un pulpo, sólo puede atender a una persona a la vez.

- Supongamos que tenemos un restaurante.
- ▶ Si tenemos una persona trabajando a una velocidad media, y nuestro restaurante hay n = 10 mesas ocupadas, ¿Qué sucede?
- Dado que tenemos una persona, y no un pulpo, sólo puede atender a una persona a la vez.
- En este caso, tendríamos un ejemplo de un trabajo que no se está realizando en paralelo (o de manera secuencial), y nuestro solitario camarero estará realizando n operaciones él solito

- Supongamos que tenemos un restaurante.
- ▶ Si tenemos una persona trabajando a una velocidad media, y nuestro restaurante hay n = 10 mesas ocupadas, ¿Qué sucede?
- Dado que tenemos una persona, y no un pulpo, sólo puede atender a una persona a la vez.
- En este caso, tendríamos un ejemplo de un trabajo que no se está realizando en paralelo (o de manera secuencial), y nuestro solitario camarero estará realizando n operaciones él solito
- ¿Cual es la mejor solución de nuestro problema? ¿Contratamos más camareros de velocidad media? ¿Contratamos el mejor camarero del país?

## Aplicaciones en el mundo matemático



▶ Sean  $v, u \in \mathbb{R}^n$  si queremos calcular w = u + v debemos calcular la suma de cada componente, esto es:



- ▶ Sean  $v, u \in \mathbb{R}^n$  si queremos calcular w = u + v debemos calcular la suma de cada componente, esto es:
- $w_i = v_i + u_i \text{ con } i = 1, 2, 3, ..., n$  (Observamos que cada  $w_i$  es independiente del resto)

- Sean  $v, u \in \mathbb{R}^n$  si queremos calcular w = u + v debemos calcular la suma de cada componente, esto es:
- $w_i = v_i + u_i \text{ con } i = 1, 2, 3, ..., n$  (Observamos que cada  $w_i$  es independiente del resto)
- Por tanto, tenemos que hacer n operaciones para obtener el valor de w. Sin embargo, si ejecutamos estas n operaciones en paralelo, nos costaría casi lo mismo que hacer la suma de dos números.

- ▶ Sean  $v, u \in \mathbb{R}^n$  si queremos calcular w = u + v debemos calcular la suma de cada componente, esto es:
- $w_i = v_i + u_i \text{ con } i = 1, 2, 3, ..., n$  (Observamos que cada  $w_i$  es independiente del resto)
- Por tanto, tenemos que hacer n operaciones para obtener el valor de w. Sin embargo, si ejecutamos estas n operaciones en paralelo, nos costaría casi lo mismo que hacer la suma de dos números.
- Esta misma idea es aplicable también para calcular el producto de un número  $\lambda$  y un vector u.

► En este ejemplo, veremos que no siempre se puede paralelizar un problema, y veremos uno de los problemas más comunes a la hora de paralelizar; Las condiciones de carrera



► En este ejemplo, veremos que no siempre se puede paralelizar un problema, y veremos uno de los problemas más comunes a la hora de paralelizar; Las condiciones de carrera

Sea  $v, u \in \mathbb{R}^n$  dos vectores a los que queremos calcular el producto escalar,  $s = u \cdot v$ . Recordemos que el producto escalar se puede calcular como la suma del producto de las componentes.

- ► En este ejemplo, veremos que no siempre se puede paralelizar un problema, y veremos uno de los problemas más comunes a la hora de paralelizar; Las condiciones de carrera
- Sea  $v, u \in \mathbb{R}^n$  dos vectores a los que queremos calcular el producto escalar,  $s = u \cdot v$ . Recordemos que el producto escalar se puede calcular como la suma del producto de las componentes.
- ▶ Para programar esto, tenemos que ir sumando a una variable real s el producto de todos los componentes,  $v_i * u_i$ .

- ► En este ejemplo, veremos que no siempre se puede paralelizar un problema, y veremos uno de los problemas más comunes a la hora de paralelizar; Las condiciones de carrera
- Sea  $v, u \in \mathbb{R}^n$  dos vectores a los que queremos calcular el producto escalar,  $s = u \cdot v$ . Recordemos que el producto escalar se puede calcular como la suma del producto de las componentes.
- ▶ Para programar esto, tenemos que ir sumando a una variable real s el producto de todos los componentes,  $v_i * u_i$ .
- ▶ Supongamos que queremos hacerlo en paralelo, y sucede que las componentes i,j se ejecutan al mismo tiempo.

▶ Por tanto, al mismo tiempo se ejecutará  $s = s + v_i * u_i$  y  $s = s + v_j * u_j$ .



- ▶ Por tanto, al mismo tiempo se ejecutará  $s = s + v_i * u_i$  y  $s = s + v_j * u_j$ .
- Al realizarse al mismo tiempo, el valor s que se suma al producto, será el mismo, por tanto, dado que sólo se asignará un valor de s (Supongamos que es i) el valor v<sub>j</sub> \* u<sub>j</sub> no se sumará a s.

- ▶ Por tanto, al mismo tiempo se ejecutará  $s = s + v_i * u_i$  y  $s = s + v_j * u_j$ .
- Al realizarse al mismo tiempo, el valor s que se suma al producto, será el mismo, por tanto, dado que sólo se asignará un valor de s (Supongamos que es i) el valor v<sub>j</sub> \* u<sub>j</sub> no se sumará a s.
- Por tanto, el producto escalar no podemos paralelizarlo, pues tenemos una condición de carrera.

▶ Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.



- ▶ Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...



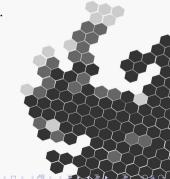
- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- Encontrar mínimos de funciones.



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- ► Encontrar mínimos de funciones.
- Encontrar gran cantidad de raíces de una función a la vez.



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- Encontrar mínimos de funciones.
- Encontrar gran cantidad de raíces de una función a la vez.
- Acelerar método de diferencias finitas.



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- ► Encontrar mínimos de funciones.
- Encontrar gran cantidad de raíces de una función a la vez.
- Acelerar método de diferencias finitas.
- Trabajar con Big Data.



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- Encontrar mínimos de funciones.
- Encontrar gran cantidad de raíces de una función a la vez.
- Acelerar método de diferencias finitas.
- Trabajar con Big Data.
  Podemos procesar muchos datos a la vez.



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- Encontrar mínimos de funciones.
- Encontrar gran cantidad de raíces de una función a la vez.
- Acelerar método de diferencias finitas.
- Trabajar con Big Data.
  Podemos procesar muchos datos a la vez.
- Acelerar todas las tareas que se hacen por fuerza bruta; Romper contraseñas, encontrar combinaciones, ...



- Resolución de sistemas de ecuaciones; Jacobi es fácilmente paralizable.
- Criptografía; Encontrar primos, blockchain...
- Cálculos con matrices.
- Encontrar mínimos de funciones.
- Encontrar gran cantidad de raíces de una función a la vez.
- Acelerar método de diferencias finitas.
- Trabajar con Big Data.
  Podemos procesar muchos datos a la vez.
- Acelerar todas las tareas que se hacen por fuerza bruta; Romper contraseñas, encontrar combinaciones, ...
- ▶ ..



## Algunos conceptos básicos



▶ Decimos que **un algoritmo de** *n* **pasos se puede paralelizar** si cada *n* iteración no depende del resto de iteraciones.



- ▶ Decimos que un algoritmo de n pasos se puede paralelizar si cada n iteración no depende del resto de iteraciones.
- ► Formas de paralelización:

CPU: Utilizando los hilos disponibles en el procesador de nuestro ordenador. Todos los hilos son de alto rendimiento, pero la cantidad de hilos es bastante pequeña.

- ▶ Decimos que **un algoritmo de** *n* **pasos se puede paralelizar** si cada *n* iteración no depende del resto de iteraciones.
- Formas de paralelización:
  - CPU: Utilizando los hilos disponibles en el procesador de nuestro ordenador. Todos los hilos son de alto rendimiento, pero la cantidad de hilos es bastante pequeña.
  - ► GPU: Utilizando los hilos disponibles en la tarjeta gráfica de nuestro ordenador. Los hilos tienen un menor desempeño que los de la CPU, sin embargo, contiene una gran cantidad de hilos.

- ▶ Decimos que **un algoritmo de** *n* **pasos se puede paralelizar** si cada *n* iteración no depende del resto de iteraciones.
- Formas de paralelización:
  - CPU: Utilizando los hilos disponibles en el procesador de nuestro ordenador. Todos los hilos son de alto rendimiento, pero la cantidad de hilos es bastante pequeña.
  - GPU: Utilizando los hilos disponibles en la tarjeta gráfica de nuestro ordenador. Los hilos tienen un menor desempeño que los de la CPU, sin embargo, contiene una gran cantidad de hilos.
  - Red: Distribuimos el trabajo entre varios ordenadores a través de una conexión de red.

## Programar en paralelo



# Trabajar con la CPU



► Función *ParallelX*[].



► Función *ParallelX*[].



- ► Función ParallelX[].
- ► Demo de ParallelX



- ► Función ParallelX[].
- ► Demo de ParallelX
- ► Función Parallelize[]



- ► Función ParallelX[].
- ► Demo de ParallelX
- ► Función Parallelize[]



- ► Función ParallelX[].
- ► Demo de ParallelX
- ► Función Parallelize[
- ▶ Demo de Parallelize



- ► Función ParallelX[].
- ► Demo de ParallelX
- ► Función Parallelize[
- ▶ Demo de Parallelize



R

► lapply:



► *lapply*: Aplicar una lista a una función y obtener el resultado.



- ► *lapply*: Aplicar una lista a una función y obtener el resultado.
- Librería paralell:



- lapply: Aplicar una lista a una función y obtener el resultado.
- Librería paralell: Esta librería nos permite paralelizar funciones en R.



► lapply: Aplicar una lista a una función y obtener el resultado.

► Librería paralell: Esta librería nos permite paralelizar funciones en R. Tenemos dos funciones importantes; detectCores() nos detecta el número de núcleos de nuestro ordenador.

- ▶ lapply: Aplicar una lista a una función y obtener el resultado.
- ▶ Librería paralell: Esta librería nos permite paralelizar funciones en R. Tenemos dos funciones importantes; detectCores() nos detecta el número de núcleos de nuestro ordenador. makeCluster(corenum) inicializa una instancia en paralelo, donde corenum es el número de núcleos que quieres usar.
- parLapply: Igual que la función lapply, pero en paralelo.
- Otras funciones interesantes: Paquete foreach, nos permite ejecutar una acción en una lista de elementos.
- Demo



La manera más convencional es usando pthread.h



- La manera más convencional es usando pthread.h
  - ► Tenemos que incluir *pthread.h*



- La manera más convencional es usando pthread.h
  - ► Tenemos que incluir *pthread.h*
  - ▶ Para ejecutar una función en paralelo, la llamamos con phtread\_create.
  - ► Si queremos esperar que un hilo termine antes de ejecutar algo, llamamos *pthread\_join*
- Con OpenMP todo esto se simplifica,

- La manera más convencional es usando pthread.h
  - ► Tenemos que incluir *pthread.h*
  - ▶ Para ejecutar una función en paralelo, la llamamos con phtread\_create.
  - Si queremos esperar que un hilo termine antes de ejecutar algo, llamamos pthread\_join
- Con OpenMP todo esto se simplifica,
  - #pragma omp parallel for



- La manera más convencional es usando pthread.h
  - ► Tenemos que incluir *pthread.h*
  - ▶ Para ejecutar una función en paralelo, la llamamos con phtread\_create.
  - Si queremos esperar que un hilo termine antes de ejecutar algo, llamamos pthread\_join
- Con OpenMP todo esto se simplifica,
  - #pragma omp parallel for
  - #pragma omp parallel
  - **.**..



- La manera más convencional es usando pthread.h
  - ► Tenemos que incluir *pthread.h*
  - ▶ Para ejecutar una función en paralelo, la llamamos con phtread\_create.
  - ► Si queremos esperar que un hilo termine antes de ejecutar algo, llamamos *pthread\_join*
- Con OpenMP todo esto se simplifica,
  - #pragma omp parallel for
  - #pragma omp parallel
  - **...**
- DEMO



# Trabajar con la GPU



► La GPU y la CPU por lo general, **NO COMPARTEN** memoria.



- ▶ La GPU y la CPU por lo general, **NO COMPARTEN** memoria.
- ▶ Copiar memoria de la CPU a la GPU (y viceversa) es lento.



- ▶ La GPU y la CPU por lo general, **NO COMPARTEN** memoria.
- ▶ Copiar memoria de la CPU a la GPU (y viceversa) es lento.
- Por tanto, necesitamos unas funciones diferentes para reservar memoria para CPU y GPU.

- ▶ La GPU y la CPU por lo general, **NO COMPARTEN** memoria.
- ▶ Copiar memoria de la CPU a la GPU (y viceversa) es lento.
- Por tanto, necesitamos unas funciones diferentes para reservar memoria para CPU y GPU.
- Las funciones que definamos en la CPU, en general, no son accesibles por la GPU.

- ▶ La GPU y la CPU por lo general, **NO COMPARTEN** memoria.
- ► Copiar memoria de la CPU a la GPU (y viceversa) es lento.
- Por tanto, necesitamos unas funciones diferentes para reservar memoria para CPU y GPU.
- Las funciones que definamos en la CPU, en general, no son accesibles por la GPU.
- ► Las variables que definamos en la CPU, en general, no son accesibles desde la GPU.



- ▶ La GPU y la CPU por lo general, **NO COMPARTEN** memoria.
- ▶ Copiar memoria de la CPU a la GPU (y viceversa) es lento.
- Por tanto, necesitamos unas funciones diferentes para reservar memoria para CPU y GPU.
- Las funciones que definamos en la CPU, en general, no son accesibles por la GPU.
- ► Las variables que definamos en la CPU, en general, no son accesibles desde la GPU.
- Existen compiladores libres, como OpenCL, sin embargo, el compilador propietario CUDA funciona mejor en gráficas NVIDIA.



## **CUDA**

► Es un lenguaje desarrollado por NVIDIA basado en C++, orientado a programar en GPU.

#### **CUDA**

Es un lenguaje desarrollado por NVIDIA basado en C++, orientado a programar en GPU.

cudaMalloc: Equivalente a malloc, pero para reservar memoria en la GPU.